

УДК 004.01:006.72 (470.22)

ОБЗОР МЕТОДОВ (УТОЧНИТЬ - КАКИХ?) ПО РЕШЕНИЮ ЗАДАЧИ РАЗРЕШЕНИЯ ЛЕКСИЧЕСКОЙ МНОГОЗНАЧНОСТИ

С. С. Ткач, Е. А. Ярышкина, А. Н. Кирилов, И. А. Сихонина

Институт прикладных математических исследований Карельского научного центра РАН

Данный файл является примером статьи для научного издания Труды Карельского научного центра РАН, серия «Математическое моделирование и информационные технологии». В нем содержатся основные используемые переменные и окружения. При подготовке статьи рекомендуется воспользоваться этим примером в качестве шаблона. Данный абзац оформлен в стиле аннотации статьи.

Ключевые слова: труды, шаблон, подготовка статьи.

S. S. Tkach, E. A. Yaryshkina, A. N. Kirilov, I. A. Sikhonina.
**WORD-SENSE DISAMBIGUATION METHODS (SPECIFIC?)
REVIEW**

This file is an auxiliary example of an article prepared for Transactions of Karelian Research Centre of RAS. It contains most useful environments and variables. While preparing your article, it's recommended to use this text as a template. This paragraph is formatted as an Abstract of the article.

Key words: transactions, template, article.

ВВЕДЕНИЕ

Статья, представляемая в научное издание, должна быть оформлена в соответствии с «Правилами для авторов», размещенными на сайте <http://transactions.krc.karelia.ru>. Данный документ претендует на роль технической документации в помощь авторам. Достаточно подробную информацию по наборе в системе L^AT_EX можно найти, напр., в работе [2].

СТРУКТУРА ФАЙЛА В ФОРМАТЕ L^AT_EX 2_ε

```
\documentclass{article}  
\usepackage{krctran}  
...  
\begin{document}
```

```
\procname{...}  
\udk{...}  
\rustitle{...}  
\engtitle{...}  
\rusauthor{...}  
\engauthor{...}  
\organization{...}  
\rusabstract{...}  
\engabstract{...}  
\ruskeywords{...}  
\engkeywords{...}
```

```
\maketitle  
  
\begin{articletext}  
\section{...}  
...
```

Рис. 1. Задержки в модели 10-узловой системы, случай тяжелых хвостов

```
\begin{thebibliography}
...
\end{thebibliography}
\end{articletext}

\section{СВЕДЕНИЯ ОБ АВТОРЕ:}
\begin{aboutauthors}
...
\end{aboutauthors}
\end{document}
```

Преамбула статьи должна содержать две обязательные команды:

```
\documentclass{article}
\usepackage{krctran}
```

Далее формируется заголовок статьи: выходные данные, код УДК, название статьи, авторы с указанием мест работы, аннотация,

ключевые слова. Например, заголовок этого файла сформирован следующими командами:

```
\procname{Труды...\ \No...}
\udk{УДК...}
\rustitle{Руководство...}
\engtitle{Usage...}
\rusauthor{А.~С.~Румянцев}
\engauthor{A.~S.~Rumyantsev}
\organization{Институт...}
\rusabstract{Данный файл...}
\engabstract{This file...}
\ruskeywords{труды,...}
\engkeywords{transactions,...}
\maketitle
```

Замечание 1. Для ручной разбивки на строки названия статьи воспользуйтесь командой `\newline`.

WSD-МЕТОДЫ С УЧИТЕЛЕМ

«WSD НА ОСНОВЕ НЕЙРОННЫХ СЕТЕЙ, ПОСТРОЕННЫХ ПО ДАННЫМ МАШИНОЧИТАЕМЫХ СЛОВАРЕЙ»

А. Н. Кирилов

Настоящий текст является рефератом статьи [13], в которой описан метод автоматического построения очень больших нейронных сетей (VLNN) с помощью текстов, извлекаемых из машинно-читаемых словарей (MRD), и рассмотрено использование этих сетей в задачах разрешения лексической неоднозначности (WSD).

В дальнейшем будем называть слова, смысл которых требуется установить целевыми словами.

Широко известен метод Леска [8] использования информации из MRD для задачи WSD. Суть этого метода состоит в вычислении так называемой «степени пересечения», т.е. количества общих слов в словарных определениях слов из контекста («окна») условного размера, содержащего целевое слово. Основным недостатком метода Леска – зависимость от словарной статьи, т.е. от слов, входящих в нее. Стратегия преодоления этого недостатка – использование словарных статей, определяющих слова, входящие в другие словарные статьи, начиная со словарных статей, соответствующих

словам из контекста. Таким образом, образуются достаточно длинные пути из слов, входящих в словарные статьи. Эта идея лежит в основе топологии (строения) VLNN.

Использование нейронных сетей для WSD было предложено в работах [7, 17]. В рассматриваемой статье для построения VLNN использован словарь Collins English Dictionary.

Топология сети. Целевое слово представлено узлом, соединенным активирующими связями со смысловыми узлами, представляющими все возможные смыслы слова, имеющиеся в словарных статьях. Каждый смысловой узел, в свою очередь, соединен активирующими связями с узлами, представляющими слова в словарной статье, соответствующей определению данного смысла. Процесс соединения повторяется многократно, создавая большую сеть взаимосвязанных узлов. В идеале сеть может содержать весь словарь. Авторы, по практическим соображениям, ограничиваются несколькими тысячами узлов и 10 – 20 тысячами соединений. Слова представлены своими леммами (каноническими формами). Узлы, представляющие различные смыслы данного слова, соединены запрещающими (подавляющими) связями.

Алгоритм функционирования сети. При запуске сети первыми активируются узлы входного слова, которое кодируется согласно принятому правилу. Затем каждый входной узел посылает активирующий сигнал своим смысловым узлам, с которыми он соединен. В результате сигналы распространяются по всей

сети в течение определенного числа циклов. В каждом цикле узлы слова и его смыслов получают обратные сигналы от узлов, соединенных с ними. Узлы конкурирующих смыслов посылают взаимно подавляющие сигналы. Взаимодействие сигналов обратной связи и подавления, в соответствии со стратегией «победитель получает все», позволяет увеличить активацию узлов-слов и соответствующих им правильных узлов-смыслов, одновременно уменьшая активацию узлов соответствующих неправильным смыслам. После нескольких десятков циклов сеть стабилизируется в состоянии, в котором активированы только узлы-смыслы с наиболее активированными связями с узлами-словами. В статье не указан алгоритм настройки, т.е. обучения сети. Видимо, используется метод встречного распространения (back propagation).

WSD-методы без учителя

«РАЗРЕШЕНИЕ МНОГОЗНАЧНОСТИ В БИОМЕДИЦИНСКИХ ТЕКСТАХ С ПОМОЩЬЮ МЕТОДОВ КЛАСТЕРИЗАЦИИ БЕЗ УЧИТЕЛЯ»

Е. А. Ярышкина

В статье [12] изучаются уже существующие методы кластеризации без учителя и их эффективность для решения лексической многозначности при обработке текстов по биомедицине. Решение проблем лексической многозначности в данной области включает в себя не только традиционные задачи присвоения ранее определенных смысловых значений для терминов, но так же и обнаружения новых значений для них, ещё не включённых в данную онтологию.

Авторы описали методологию метода решения лексической многозначности без учителя, учитываемые лексические признаки и наборы экспериментальных данных. В качестве оценки эффективности алгоритмов кластеризации текста была предложена F-мера.

Подход для решения поставленной задачи – это разделение контекстов (фрагментов текста), содержащих определенное целевое слово на кластеры, где каждый кластер представляет собой различные значения целевого слова. Каждый кластер состоит из близких по значению контекстов. Задача решается в предположении, что используемое целевое слово в аналогичном контексте будет иметь один и тот же или очень похожий смысл.

Процесс кластеризации продолжается до тех пор, пока не будет найдено предварительно заданное число кластеров. В данной статье выбор шести кластеров основан на том факте, что это больше, чем максимальное число возможных значений любого английского слова, наблюдаемое среди данных (большинство слов имеют два-три значения). Нормализация текста не выполняется.

Данные в этом исследовании состоят из ряда контекстов, которые включают данное целевое слово, где у каждого целевого слова вручную отмечено – какое значение из словаря было использовано в этом контексте. Контекст – это единственный источник информации о целевом слове. Цель исследования – преобразовать контекст в контекстные вектора первого и второго порядка [4]. Контекстные вектора содержат следующие «лексические свойства»: биграммы, совместную встречаемость и совместную встречаемость целевого слова. Биграммами являются как двухсловные словосочетания, так и любые два слова, расположенные рядом в некотором тексте. Для лингвистических исследований могут быть полезны только упорядоченные наборы биграмм [3].

Экспериментальные данные – это набор NLM WSD [16] (NLM – национальная библиотека медицины США), в котором значения слов взяты из UMLS (единая система медицинской терминологии). UMLS имеет три базы знаний:

- Метатезаурус включает все термины из контролируемых словарей (SNOMED-CT, ICD и другие) и понятия, которые представляют собой кластеры из терминов, описывающих один и тот же смысл.
- Семантическая сеть распределяет понятия на 134 категории и показывает отношения между ними. SPECIALIST-лексикон содержит семантическую информацию для терминов Метатезауруса.
- Medline – главная библиографическая база данных NLM, которая включает приблизительно 13 миллионов ссылок на журнальные статьи в области науки о жизни с уклоном в биомедицинскую область.

Авторы успешно проверили по три конфигурации существующих методов (PB – Pedersen and Bruce [10], SC – Sch?tze [15]) и оценили эффективность использования SVD (сингулярное разложение матриц). Методы PB основаны на контекстных векторах первого порядка – признаки одновременного при-

сутствия целевого слова или биграммы. Рассчитывается среднее расстояние между кластерами или применяется метод бисекций. РВ методы подходят для работы с довольно большими наборами данных. Методы SC основаны на представлениях второго порядка – матрицы признаков одновременного присутствия или биграммы, где каждая строка и столбец – вектор признаков первого порядка данного слова. Так же рассчитывается среднее расстояние между кластерами или применяется метод бисекций. SC методы подходят для обработки небольших наборов данных.

Метод SC2 (признаки одновременного присутствия второго порядка, среднее расстояние между элементами кластера в пространстве подобия) с применением и без SVD показал лучшие результаты: всего 56 сравниваемых экземпляров, в 47 случаях метод SC2 показал наилучшие результаты, в 7 случаях результаты незначительно отличаются от других проверяемых методов.

Все эксперименты, указанные в исследовании, выполнялись с помощью пакета SenseClusters [14]. В ходе исследования было проведено два эксперимента для разных наборов данных. Маленький тренировочный набор – это набор NLM WSD, который включает 5000 экземпляров для 50 часто встречаемых неоднозначных терминов из Метатезауруса UMLS. Каждый неоднозначный термин имеет по 100 экземпляров с указанным вручную значением. У 21 термина максимальное число экземпляров находится в пределах от 45 до 79 экземпляров. У 29 терминов число экземпляров от 80 до 100 для конкретного значения. Стоит отметить, что каждый термин имеет категорию «ни одно из вышеупомянутых», которая охватывает все оставшиеся значения, не соответствующие доступным в UMLS. Большой тренировочный набор является реконструкцией «1999 Medline», который был разработан Weeber [18]. Были определены все формы из набора NLM WSD и сопоставлены с тезисами «1999 Medline». Для создания тренировочного набора экземпляров использовались только те тезисы из «1999 Medline», которым было найдено соответствие в наборе NLM WSD.

Использование целиком текста аннотации статьи в качестве контекста приводит к лучшим результатам, чем использование отдельных предложений. С одной стороны, большой объем контекста, представленный аннотацией, дает богатую коллекцию признаков, с другой стороны, в коллекции WSD представлено небольшое число контекстов.

WSD-МЕТОДЫ, ОСНОВАННЫЕ НА ЗНАНИЯХ

«ПОСТРОЕНИЕ СОЧЕТАЕМОСТНЫХ ОГРАНИЧЕНИЙ НА ОСНОВЕ БАЙЕСОВСКИХ СЕТЕЙ ДЛЯ РАЗРЕШЕНИЯ МНОГОЗНАЧНОСТИ»

И. А. Сихонина

В статье [6] представлена Байесовская модель, применяемая для разрешения лексической многозначности глаголов. Авторы рассматривают такое понятие, как сочетаемостные ограничения (selectional preferences). *Сочетаемостные ограничения* (далее SP) – это закономерности использования глагола относительно семантического класса его параметров (субъект, объект (прямое дополнение) и косвенное дополнение).

Модели автоматического построения SP важны сами по себе и имеют приложения в обработке естественного языка. Сочетаемостные ограничения глагола могут применяться для получения возможных значений неизвестного параметра при известных глаголах; например, из предложения «*Осенние xxxx жуужжали и бились на стекле*» легко определить, что “xxxx” – мухи. При построении предложения SP позволяют отранжировать варианты и выбрать лучший среди них. Исследование SP могло бы помочь в понимании структуры ментального лексикона.

Системы обучения SP без учителя обычно комбинируют статистические подходы и подходы, основанные на знаниях. Компонент базы знаний (здесь WordNet [9]) – это обычно база данных, в которой слова сгруппированы в классы.

Статистический компонент состоит из пар предикат-аргумент, извлечённых из неразмеченного корпуса. В тривиальном алгоритме можно было бы получить список слов (прямых дополнений глагола), и для тех слов, которые есть в WordNet, вывести их семантические классы. В работе [6] семантическим классом называется синсет (группа синонимов) тезауруса WordNet, то есть класс соответствует одному из значений слова. Таким образом, в тривиальном алгоритме на основе данных WordNet можно выбрать классы (значения слов), с которыми употребляются (встречаются в корпусе) глаголы.

Например, если в исходном корпусе текстов глагол *ползать* употребляется со словом *ящерица*, принадлежащим классу РЕПТИЛИИ, то в модели построения SP будет записано,

что «глагол *ползать* употребляется со словами из класса РЕПТИЛИИ». Если слово *крокодил*, во-первых, также встречается в тексте с глаголом *ползать*, во-вторых, слово *крокодил* принадлежит сразу двум классам: РЕПТИЛИЯ и ВЕРТОЛЁТ, то из этого следует, что модель SP будет расширена информацией о том, что «глагол *ползать* употребляется со словами из классов и РЕПТИЛИЯ, и ВЕРТОЛЁТ».

В ранее разработанных моделях (Резник (1997) [11], Абни и Лайт (1999) [5]) было обнаружено, что главная трудность в таком тривиальном алгоритме – это наличие неоднозначных слов в обучающих данных. В тех же работах ([11], [5]) были предложены более сложные модели, в которых предполагается, что все значения многозначных слов появляются с одинаковой частотой.

Байесовские сети или Байесовские сети доверия (БСД) состоят из множества переменных (вершин) и множества ориентированных ребер, соединяющих эти переменные. Такой сети соответствует ориентированный ациклический граф. Каждая переменная может принимать одно из конечного числа взаимоисключающих состояний. Пусть все переменные будут бинарного типа, то есть принимают одно из двух значений: истина или ложь. Любой переменной A с родителями B_1, \dots, B_n соответствует таблица условных вероятностей (conditional probability table, далее СРТ).

Например, построим SP для глагола *ползать* и сеть на рисунке 2 будет базой знаний.




Рис. 2. Байесовская сеть для многозначного существительного *крокодил*

Глагол *ползать* употребляется со словами *крокодил* и *ящерица*. Переменные ВЕРТОЛЁТ и РЕПТИЛИЯ соответствуют более общим абстрактным значениям, переменные *крокодил* и *ящерица* являются более узкими, конкретными значениями. Переменная РЕПТИЛИЯ может принимать одно из двух значений, соответствующих словам *крокодил* и *ящерица*,

именно эту задачу определения значения и нужно решить.

Таблица 1. Условные вероятности переменных *крокодил* и *ящерица* в зависимости от значений переменных ВЕРТОЛЁТ и РЕПТИЛИЯ, где (В, Р, к, я – это аббревиатуры слов ВЕРТОЛЁТ, РЕПТИЛИЯ, *крокодил* и *ящерица*)

	$P(X = x Y_1 = y_1, Y_2 = y_2)$			
	В,Р	В,¬Р	¬В,Р	¬В, ¬Р
к = <i>true</i>	0,99	0,99	0,99	0,01
к = <i>false</i>	0,01	0,01	0,01	0,99
я = <i>true</i>	0,99	0,99	0,01	0,01
я = <i>false</i>	0,01	0,01	0,99	0,99

При построении таблицы 1 условных вероятностей (СРТ), учтём следующие предположения:

- вероятность, что выбираем какой-либо из концептов (ВЕРТОЛЁТ и РЕПТИЛИЯ) очень мала, то есть $P(B=true) = P(P=true) = 0,01$, следовательно, велика вероятность, что концепты не выбраны: $P(B=false) = P(P=false) = 0,99$;
- если какой-либо из концептов истинен (В, Р), то «выпадает» слово *крокодил*;
- если концепт РЕПТИЛИЯ истинен, то растут шансы встретить слово *ящерица*;

Из таблицы 1 вероятности появления слов следует вывод, что использование сразу двух значений слова *крокодил* (*рептилия* и *вертолёт МИ-24*) маловероятно. Вероятность использования значения РЕПТИЛИЯ намного больше чем значения ВЕРТОЛЁТ. Таким образом гипотеза «вертолёт» «отброшена» (“explaining away”).

Байесовские сети для построения SP. Иерархия существительных в WordNet представлена в виде ориентированного ациклического графа. Синсет узла принимает значение «истина», если глагол «выбирает» существительное из набора синонимов. Априорные вероятности задаются на основе двух предположений: во-первых, маловероятно, что глагол будет употребляться только со словами какого-то конкретного синсета, и во-вторых, если глагол действительно употребляется только со словами из данного синсета (например, синсет ЕДА), тогда должно быть правомерным употребление этого глагола с гипонимами этого синсета (например, ФРУКТ).

Те же предположения (что для синсетов) верны и для употреблений слов с глаголами:

1. слово, вероятно, является аргументом глагола в том случае, если глагол употребляется с каким-либо из значений этого слова;
2. отсутствие связки глагол-синсет говорит о малой вероятности того, что слова этого синсета употребляются с глаголом;

Словам «вероятно» и «маловероятно» должны быть приписаны такие числа, сумма которых равна единице.

Находкой работы [6] является разъяснение стратегии “explaining away”, то есть отбрасывание маловероятных значений слов при построении сочетаемостных ограничений. Такая стратегия является неотъемлемым свойством Байесовских сетей и Байесовского вывода, полезным свойством при разрешении лексической многозначности.

Библиография

Библиографические ссылки принято оформлять в виде [номер], в отличие от ранее принятых [Автор, год] (см., напр., [1]). Источники, процитированные выше, были набраны командой

```
\bibitem{Trans}
\textit{Борисов~Г.~А.,
Тихомирова~Т.~А.}
Характеристики и свойства потерь
энергии и мощности на пределах
энергетического хозяйства региона //
Труды Карельского научного центра
Российской академии наук. 2010.
\No 3. С.~4--10.
```

ТЕОРЕМОПОДОБНЫЕ ОКРУЖЕНИЯ

Для теорем, утверждений и пр. необходимо использовать соответствующие окружения. Например:

Утверждение 1. *В предложенной модели системы обслуживания при $\rho = ES/ET < 1$ условие $ES^{\alpha+1} < \infty$ является достаточным для конечности момента порядка α времени ожидания в системе, $ED^{\alpha} < \infty$.*

Доказательство. Очевидно. □

В данном случае было использовано окружение `\begin{State}... \end{State}`. Для набора доказательства использовалось окружение `\begin{proof}... \end{proof}`. Доступные автору теоремоподобные окружения перечислены в Таблице 2.

Таблица 2. Теоремоподобные окружения

Theorem	Теорема
Lemma	Лемма
State	Утверждение
Corollary	Следствие
Axiom	Аксиома
Definition	Определение
Example	Пример
Remark	Замечание

Для определений, примеров и замечаний используется прямое написание.

Пример. Например, как в этом примере.

Соответствующие версии окружений «созвездий» также работают. Пример выше был набран такой командой:

```
\begin{Example*}
Например, как в этом примере.
\end{Example*}
```

Таблица 3. Таблица, демонстрирующая возможность размещения на всю ширину страницы


Первая колонка	вторая колонка	третья колонка	четвертая колонка	пятая колонка
----------------	----------------	----------------	-------------------	---------------

Рисунки и таблицы

Рисунки и таблицы могут вставляться как на всю ширину страницы, так и на ширину колонки. Желательно использовать рисунки формата pdf. Для конвертации из формата eps можно воспользоваться утилитой `epstopdf`. Так, например, Рис. 3 был вставлен на ширину колонки командой

```
\begin{figure}[H]
\includegraphics[keepaspectratio=true,
```

```
width=0.9\columnwidth]{delay_80.pdf}
\caption{Задержки в модели
10-узловой системы}
\label{fig1}
\end{figure}
```



delay_80.pdf

Рис. 3. Задержки в модели 10-узловой системы

$$Y = A_1x + A_2x^2 + \dots + A_nx^n. \quad (1)$$

Набран пример следующим образом:

```
\bfullwidth
\begin{equation}
Y=A_1x+A_2x^2+\ldots +A_nx^n.
\end{equation}
\efullwidth
```

Пример размещения таблицы на ширину страницы (см. таблицу 3):

```
\bfullwidth
\centering
\begin{table}[H]
\begin{tabular}{|c|c|c|c|c|}
\hline
Первая колонка & ...\\
\hline
\end{tabular}
\label{tab_width}
\end{table}
\efullwidth
```

Рис. 1 демонстрирует возможности вставки по всей ширине страницы. Это было достигнуто при помощи команды

```
\bfullwidth
\begin{figure}
\includegraphics[height=100mm,...]
\caption{Задержки в модели...}
\label{fig5}
\end{figure}
\efullwidth
```

Следует обратить внимание на то, что вышеуказанная команда вставит рисунок не ближе,

РАЗМЕЩЕНИЕ НА ВСЮ ШИРИНУ СТРАНИЦЫ

В стилевом файле предусмотрена возможность размещения формул, рисунков и таблиц на ширину страницы. Для этого размещаемый элемент необходимо заключить между командами `\bfullwidth` и `\efullwidth`.

Пример формулы на всю ширину страницы:

чем на следующей странице сверху, а не сразу на месте указания команды.

СВЕДЕНИЯ ОБ АВТОРАХ

После основного текста оформляются сведения об авторах. Используется окружение `\begin{aboutauthors}...\end{aboutauthors}`. При этом следует обратить внимание, что работа ведется в двухколоночном режиме, поэтому необходимо вручную указать разрыв колонки для отделения сведений на русском и английском языках. Например:

```
\begin{aboutauthors}
\authorsname{Румянцев Александр...}
аспирант\\
...
\columnbreak
\authorsname{Rumyantsev, Alexander}
...
\end{aboutauthors}
```

ЗАКЛЮЧЕНИЕ

Компиляцию исходного файла желательно выполнять с помощью макроса `pdflatex`.

В работе рассмотрены основные технические аспекты подготовки статьи для сборника Трудов Карельского научного центра РАН. Предложения и пожелания по доработке стилевых файлов, а также текста этого документа принимаются по электронному адресу, указанному в разделе «Сведения об авторах».

ЛИТЕРАТУРА

1. *Борисов Г. А., Тихомирова Т. А.* Характеристики и свойства потерь энергии и мощности на пределах энергетического хозяйства региона // Труды Карельского научного центра Российской академии наук. 2010. №3. С. 4–10.
2. *Львовский С. М.* Набор и верстка в системе L^AT_EX. М., 2003. 448 с.
3. *Аверин, А.Н.* Разработка сервиса поиска биграмм // Труды международной конференции «Корпусная лингвистика–2006. СПб., С.Петербург. ун-та., 2006.
4. *Енрев, А. С.* Применение контекстных векторов в классификации текстовых документов. 2010. <http://jre.cplire.ru/iso/oct10/1/text.html>
5. *Abney, S. and Light, M.* Hiding a semantic hierarchy in a markov model. In Proceedings of the Workshop on Unsupervised Learning in Natural Language Processing, ACL. 1999.
6. *Ciaramita, M. and Johnson, M.* Explaining away ambiguity: Learning verb selectional preference with Bayesian networks. 2000.
7. *COTTRELL, G. W. and SMALL, S. L.* A connectionist scheme for modelling word sense disambiguation – Cognition and brain theory. 1983. № 6. P. 89–120.
8. *LESK, M.* Automatic sense disambiguation using machine readable dictionaries: How to tell a pine cone from an ice cream cone – Proceedings of the 5th SIGDOC. New York. 1986. P. 24–26.
9. *Miller, G.* Wordnet: An on-line lexical database. International Journal of Lexicography, 3(4). 1990.
10. *Pedersen, T. and Bruce, R.* Distinguishing word senses in untagged text. Proc. EMNLP. Providence, RI, 1997.
11. *Resnik, P.* Selectional preference and sense disambiguation. In Proceedings of the ANLP-97 Workshop: Tagging Text with Lexical Semantics: Why, What, and How? 1997.
12. *Savova, G.* Resolving ambiguities in biomedical text with unsupervised clustering approaches. University of Minnesota Supercomputing Institute Research Report, 2005.
13. *VERONIS, J. and IDE, N.* Word sense disambiguation with very large neural networks extracted from machine readable dictionaries – Proceedings of the 13th International Conference on Computational Linguistics. Helsinki. 1990. P. 389–394.
14. *SenseClusters* <http://senseclusters.sourceforge.net>
15. *Schutze, H.* Automatic Word Sense Discrimination. Computational Linguistics, vol. 24, number 1., 1998.
16. UMLS Terminology Services (UTS). <http://umlsks.nlm.nih.gov/kss/servlet/Turbine/template>
17. *WALTZ, D. L. and POLLACK, J. B.* Massively parallel parsing: a strongly interactive model of natural language interpretation – Cognitive science. 1985. № 9. P. 51–74.
18. *Weeber, M. and Mork, J. and Aronson, A.* Developing a test collection for biomedical word sense disambiguation. Proc. AMIA., 2001.

СВЕДЕНИЯ ОБ АВТОРЕ:

Кирилов Александр Николаевич

доктор физико-математических наук
доцент
Институт прикладных математических исследований
КарНЦ РАН
ул. Пушкинская, 11, Петрозаводск, Республика Карелия, Россия, 185910
эл. почта: kirillov@krc.karelia.ru
тел.: (8142) 766312

Румянцев Александр Сергеевич

аспирант
Институт прикладных математических исследований
КарНЦ РАН
ул. Пушкинская, 11, Петрозаводск, Республика Карелия, Россия, 185910
эл. почта: ar0@krc.karelia.ru
тел.: (8142) 763370

Сихонина Ирина Александровна

Математический факультет
Петрозаводский государственный университет
пр-кт Ленина, 33, Петрозаводск, Республика Карелия
тел.: +7(8142) 71-10-78
syawenka@mail.ru

Kirilov, Alexander

Doctor (DSc) of Physics and Mathematics
Assistant Professor
Institute of Applied Mathematical Research, Karelian Research Centre, Russian Academy of Science
11 Pushkinskaya St., 185910 Petrozavodsk, Karelia, Russia
e-mail: kirillov@krc.karelia.ru
tel.: (8142) 766312

Rumyantsev, Alexander

Institute of Applied Mathematical Research, Karelian Research Centre, Russian Academy of Science
11 Pushkinskaya St., 185910 Petrozavodsk, Karelia, Russia
e-mail: ar0@krc.karelia.ru
tel.: (8142) 763370

Sikhonina, Irina

Student
Faculty of Mathematics
Petrozavodsk State University
Prospect Lenina, 33, Petrozavodsk, Republic of Karelia
tel.: +7(8142) 71-10-78
syawenka@mail.ru

Ткач Станислав Сергеевич
Математический факультет
Петрозаводский государственный университет
пр-кт Ленина, 33, Петрозаводск, Республика Карелия
тел.: +7 (8142) 71-10-78
tkachkras@gmail.com

Tkach, Stanislav
Student
Faculty of Mathematics
Petrozavodsk State University
Prospect Lenina, 33, Petrozavodsk, Republic of Karelia
tel.: +7 (8142) 71-10-78
tkachkras@gmail.com

Ярышкина Екатерина Александровна
Студентка
Математический факультет
Петрозаводский государственный университет
пр-кт Ленина, 33, Петрозаводск, Республика Карелия
+7 (8142) 71-10-78
kate.rysh@gmail.com

Yaryshkina, Ekaterina
Student
Faculty of Mathematics
Petrozavodsk State University
Prospect Lenina, 33, Petrozavodsk, Republic of Karelia
+7 (8142) 71-10-78
kate.rysh@gmail.com